


Trabajo Weka – Diabetes

ALUMNO: Morales Valverde Antony Rodrigo

CURSO: Ingeniería del Conocimiento

Primero cargamos el dataset de diabetes que trae por defecto Weka.

Figura 1.
Dataset cargado.



Luego haremos un primer entreno de clasificación usando J48 (Algoritmo de árboles de decisión) sin preprocesar los datos para luego hacer una comparación. ‘-C 0.25’ o ConfidenceFactor’ controla la poda, es decir, controla que tanto recorta ramas que no aportan nada, para evitar sobreajustes. Entonces, por encima de 0.25 (intermedio) la poda es suave y por debajo de ella es agresiva, ósea menos confianza igual a más poda. Por otro lado, ‘-M 2’ es el mínimo de instancias por hoja, subirlo a 10 o 15 suele dar un árbol más simple y con generalización. 2 es el mínimo por defecto. Entonces, ‘-M 2’ actúa mientras se construye el árbol y ‘-C 0.25’ lo hace después (poda).

Ahora, usamos ‘Cross Validation’ para medir que tan bien funciona el modelo con nuevos datos/pacientes. En cambio, si usáramos ‘Use training test’ evaluamos el modelo con datos que ya vio, y eso no nos sirve.

Figura 2.
Configuración del entreno.

Classifier

Choose **J48 -C 0.25 -M 2**

Test options

☐ Use training set

☐ Supplied test set Set...

☒ Cross-validation Folds

☐ Percentage split %

More options...

(Nom) class ▼

Start Stop

Posteriormente presionamos 'start' para realizar el entrenamiento y obtener el modelo.

Figura 3.
Resultados del entrenamiento del modelo con datos sin preprocesar

```

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      567           73.8281 %
Incorrectly Classified Instances    201           26.1719 %
Kappa statistic                    0.4164
Mean absolute error                 0.3158
Root mean squared error             0.4463
Relative absolute error             69.4841 %
Root relative squared error         93.6293 %
Total Number of Instances          768

=== Detailed Accuracy By Class ===

                TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
                0,814    0,403    0,790     0,814    0,802      0,417    0,751    0,811    tested_negative
                0,597    0,186    0,632     0,597    0,614      0,417    0,751    0,572    tested_positive
Weighted Avg.   0,738    0,327    0,735     0,738    0,736      0,417    0,751    0,727

=== Confusion Matrix ===


  a  b  <-- classified as
407 93 |  a = tested_negative
108 160 |  b = tested_positive

```

Visualización del árbol con tree-J48 para los datos antes de preprocesar.


Figura 4.

Árbol de decisión del modelo entrenado del dataset sin preprocesar.



Ahora, iniciamos con el preprocesamiento de datos, en donde aplicamos un filtro NumericCleaner para filtrar ceros.


Figura 5.
Dataset diabetes filtrados (NumericCleaner)



No.	1: preg Numeric	2: plas Numeric	3: pres Numeric	4: skin Numeric	5: insu Numeric	6: mass Numeric	7: pedi Numeric	8: age Numeric	9: class Nominal
1	6.0	148.0	72.0	35.0		33.6	0.627	50.0	tested...
2	1.0	85.0	66.0	29.0		26.6	0.351	31.0	tested...
3	8.0	183.0	64.0			23.3	0.672	32.0	tested...
4	1.0	89.0	66.0	23.0	94.0	28.1	0.167	21.0	tested...
5	0.0	137.0	40.0	35.0	168.0	43.1	2.288	33.0	tested...
6	5.0	116.0	74.0			25.6	0.201	30.0	tested...
7	3.0	78.0	50.0	32.0	88.0	31.0	0.248	26.0	tested...
8	10.0	115.0				35.3	0.134	29.0	tested...
9	2.0	197.0	70.0	45.0	543.0	30.5	0.158	53.0	tested...
10	8.0	125.0	96.0				0.232	54.0	tested...
11	4.0	110.0	92.0			37.6	0.191	30.0	tested...
12	10.0	168.0	74.0			38.0	0.537	34.0	tested...
13	10.0	139.0	80.0			27.1	1.441	57.0	tested...
14	1.0	189.0	60.0	23.0	846.0	30.1	0.398	59.0	tested...
15	5.0	166.0	72.0	19.0	175.0	25.8	0.587	51.0	tested...
16	7.0	100.0				30.0	0.484	32.0	tested...
17	0.0	118.0	84.0	47.0	230.0	45.8	0.551	31.0	tested...
18	7.0	107.0	74.0			29.6	0.254	31.0	tested...
19	1.0	103.0	30.0	38.0	83.0	43.3	0.183	33.0	tested...
20	1.0	115.0	70.0	30.0	96.0	34.6	0.529	32.0	tested...
21	3.0	126.0	88.0	41.0	235.0	39.3	0.704	27.0	tested...
22	8.0	99.0	84.0			35.4	0.388	50.0	tested...
23	7.0	196.0	90.0			39.8	0.451	41.0	tested...
24	9.0	119.0	80.0	35.0		29.0	0.263	29.0	tested...

En la dataset teníamos en las columnas 2 hasta el 6 la existencia de ceros, en los demás no. Por eso indicamos eso en la celda 'attributeIndices'. NaN (missing) para no inventar datos en minDefault, el número de los 'max' es el número más negativo posible 'como menos infinito'; y entonces Weka dice: Si el valor es menor que minThreshold, ponle minDefault.

Figura 6.
Especificaciones de datos



Entonces, 'missing' en cada atributo resulta así:

- Mass: 11(1%)
- Insu 374(49%)
- Skin 227(30%)
- Pres 35(5%)

- Plas 5(1%)

Luego porfin podremos clasificar el dataset preprocesado. No hay que preocuparnos por imputar los missings. J48, RandomTree y RandomForest reparten las instancias entre sus ramas según la importancia matemática, ignoran el valor restante pero no la fila a la que pertenecen. Rescatar esos datos ayuda bastante, porque en un dataset de poco más de 700 datos, eliminar 374 porque no existe insulina es una pérdida significativa. Entonces luego podremos entrenar luego de preprocesar.

Figura 7.

Resultados del entrenamiento de un modelo con dataset preprocesado

```

=== Stratified cross-validation ===
=== Summary ===

Correctly Classified Instances      564          73.4375 %
Incorrectly Classified Instances    204          26.5625 %
Kappa statistic                    0.4019
Mean absolute error                 0.3134
Root mean squared error             0.4244
Relative absolute error             68.9539 %
Root relative squared error         89.0299 %
Total Number of Instances          768

=== Detailed Accuracy By Class ===

          TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
          0,822   0,429   0,781     0,822   0,801     0,403   0,788    0,851   tested_negative
          0,571   0,178   0,632     0,571   0,600     0,403   0,788    0,632   tested_positive
Weighted Avg.   0,734   0,341   0,729     0,734   0,731     0,403   0,788    0,775


=== Confusion Matrix ===

  a  b  <-- classified as
411 89 |  a = tested_negative
115 153 | b = tested_positive

```

A su vez también mostramos el árbol de decisión resultante para este caso.

Figura 8.
Árbol de decisión del modelo con dataset preprocesado



Entonces, gracias a estos resultados podremos hacer la comparación entre ambos modelos, los cuales se clarifican en las siguientes tablas:

Tabla 2

Métricas globales de J48 con datos sin preprocesar y preprocesados

Métrica	Sin preprocesar	Preprocesado	Diferencia
Instancias correctas	567 (73,83 %)	564 (73,44 %)	−3 (−0,39 pp)
Instancias incorrectas	201 (26,17 %)	204 (26,56 %)	+3 (+0,39 pp)
Kappa	0,4164	0,4019	−0,0145
MAE	0,3158	0,3134	−0,0024
RMSE	0,4463	0,4244	−0,0219
RAE (%)	69,48	68,95	−0,53
RRSE (%)	93,63	89,03	−4,60
MCC	0,417	0,403	−0,014
Área ROC	0,751	0,788	+0,037
Área PRC (ponderada)	0,727	0,775	+0,048

Nota. Validación cruzada estratificada de 10 particiones, N = 768.

Tabla 3*Métricas por clase de J48 con datos sin preprocesar y preprocesados*

Métrica	Clase	Sin preprocesar	Preprocesado	Diferencia
Exhaustividad (TP rate)	Negativa	0,814	0,822	+0,008
	Positiva	0,597	0,571	-0,026
Tasa de FP	Negativa	0,403	0,429	+0,026
	Positiva	0,186	0,178	-0,008
Precisión	Negativa	0,790	0,781	-0,009
	Positiva	0,632	0,632	0,000
Medida F	Negativa	0,802	0,801	-0,001
	Positiva	0,614	0,600	-0,014
Área PRC	Negativa	0,811	0,851	+0,040
	Positiva	0,572	0,632	+0,060

Nota. Clase negativa = *tested_negative*; clase positiva = *tested_positive*.

Tabla 4*Matrices de confusión de J48 con datos sin preprocesar y preprocesados*

Configuración	Clase real	Predicha negativa	Predicha positiva
Sin preprocesar	<i>tested_negative</i>	407	93
	<i>tested_positive</i>	108	160
Preprocesado	<i>tested_negative</i>	411	89
	<i>tested_positive</i>	115	153

Nota. Cada fila corresponde a la clase real de las 768 instancias (500 negativas y 268 positivas).